



INSTITUTO POLITÉCNICO NACIONAL CENTRO DE INVESTIGACIÓN EN COMPUTACIÓN

ALUMNO:

Guadalupe Javier Armenta García

MATERIA:

Recuperación de la Información Textual

PROGRAMA:

Maestría en Ciencias de la Computación

TAREA:

FreeLing y librería Stanza

FECHA:

15 de mayo del 2020

Stanza

Es un paquete de análisis de lenguaje natural de Python. Contiene herramientas, que se pueden usar en una tubería, para convertir una cadena de texto en lenguaje humano en listas de oraciones y palabras. Sirve para:

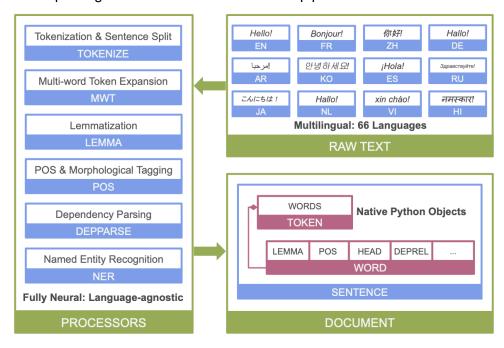
- Generar formas básicas de esas palabras
- Sus partes del discurso y características morfológicas
- Para dar un análisis de dependencia de estructura sintáctica
- Para reconocer entidades con nombre.

El kit de herramientas está diseñado para ser paralelo entre más de 70 idiomas, utilizando el *Universal Dependencies formalism.*

Características:

- 1. Implementación nativa de Python que requiere esfuerzos mínimos para configurar
- Full neural network pipeline para análisis de texto robusto, que incluye tokenization, multi-word token (MWT) expansion, lemmatization, part-of-speech (POS) y morphological features tagging, dependency parsing y named entity recognition
- 3. Modelos neuronales entrenados que admiten 66 lenguajes (humanos);
- 4. Una interfaz Python estable y oficialmente mantenida para CoreNLP.

Descripción general de neural network NLP pipeline de Stanza:



INSTALACION DE STANZA

Para ello se usó del instalador de paquetes de python 'pip', ejecutando en el siguiente comando.

```
pip install stanza
```

EJECUCION DE STANZA

Una vez instalado Stanza se descargó el paquete de idioma en inglés y se ejecutó el primer pipeline para probar su correcta instalación. (El código es ejecutado sobre Anaconda).

```
In [4]: import stanza
    stanza.download('en') # download the english model
    nlp = stanza.Pipeline('en') # initialize English neural pipeline
    doc = nlp("Barack Obama was born in Hawaii.") # run annotation over a sentence
```

Debido a que ya se había descargado el paquete en ingles indicará que existía previamente.

```
Downloading https://raw.githubusercontent.com/stanfordnlp/stanza-resources/master/resources 1.0.0.json: 116kB [00:0
2020-04-28 12:59:12 INFO: Downloading default packages for language: en (English)...
2020-04-28 12:59:13 INFO: File exists: /home/javier/stanza_resources/en/default.zip.
2020-04-28 12:59:19 INFO: Finished downloading models and saved to /home/javier/stanza_resources. 2020-04-28 12:59:19 INFO: Loading these models for language: en (English):
| Processor | Package
  tokenize
                   ewt
  pos
lemma
                    ewt
                    ewt
  depparse
                    ewt
  ner
                   ontonotes
2020-04-28 12:59:19 INFO: Use device: cpu
2020-04-28 12:59:19 INFO: Loading: tokenize
2020-04-28 12:59:19 INFO: Loading: pos
2020-04-28 12:59:20 INFO: Loading: lemma
2020-04-28 12:59:20 INFO: Loading: depparse
2020-04-28 12:59:21 INFO: Loading: ner
2020-04-28 12:59:21 INFO: Done loading processors!
```

Tokenization

```
import stanza
nlp = stanza.Pipeline(lang='en', processors='tokenize') # args: lang in english, processor to be used= Tokenizer
doc = nlp('Javier is excited to learn more about stanza')
for i, sentence in enumerate(doc.sentences):
    print(f'===== Sentence {i+1} tokens ======')
    print(*[f'id: {token.id}\ttext: {token.text}' for token in sentence.tokens], sep='\n')
2020-04-28 13:08:36 INFO: Loading these models for language: en (English):
| Processor | Package |
| tokenize | ewt
2020-04-28 13:08:36 INFO: Use device: cpu
2020-04-28 13:08:36 INFO: Loading: tokenize
2020-04-28 13:08:36 INFO: Done loading processors!
===== Sentence 1 tokens ======
id: 1 text: Javier id: 2 text: is
id: 3
        text: excited
        text: to
id: 4
id: 5
        text: learn
id: 6
        text: more
        text: about
id: 7
        text: stanza
id: 8
```

Morphological features tagging

```
nlp = stanza.Pipeline(lang='en', processors='tokenize,mwt,pos') # applying tokenizer, POSprocessor and MWTpro...
##Running the POSProcessor requires the TokenizeProcessor and MWTProcessor.
doc = nlp('Javier is excited to learn more about stanza')
 print(*[f'word: \{word.text\} \land upos\} \land xpos\} \land xpos xpos\} \land xpos xpos\} \land xpos xpos\} \land xpos\} \land xpos\} \land xpos xpos\} \land xpos\} \land xpos xpos xpos\} \land xpos xpos
                             for sent in doc.sentences for word in sent.words], sep='\n')
2020-04-28 13:13:14 WARNING: Can not find mwt: default from official model list. Ignoring it.
2020-04-28 13:13:14 INFO: Loading these models for language: en (English):
| Processor | Package |
 | tokenize | ewt
 pos
                                          l ewt
2020-04-28 13:13:14 INFO: Use device: cpu
2020-04-28 13:13:14 INFO: Loading: tokenize
2020-04-28 13:13:14 INFO: Loading: pos
2020-04-28 13:13:15 INFO: Done loading processors!
word: Javier
                                                       upos: PROPN
                                                                                                               xpos: NNP
                                                                                                                                                                      feats: Number=Sing
word: is
                                                       upos: AUX
                                                                                                               xpos: VBZ
                                                                                                                                                                       feats: Mood=Ind|Number=Sing|Person=3|Tense=Pres|VerbForm=Fin
word: excited
                                                       upos: ADJ
                                                                                                               xpos: JJ
                                                                                                                                                                       feats: Degree=Pos
word: to
                                                       upos: PART
                                                                                                               xpos: TO
                                                                                                                                                                       feats:
word: learn
                                                       upos: VERB
                                                                                                               xpos: VB
                                                                                                                                                                       feats: VerbForm=Inf
                                                                                                                                                                       feats:
                                                       upos: ADV
                                                                                                               xpos: RBR
word: more
word: about
                                                       upos: ADP
                                                                                                               xpos: IN
                                                                                                                                                                       feats:
                                                       upos: NOUN
                                                                                                                                                                      feats: Number=Sing
word: stanza
                                                                                                               xpos: NN
```

Como podemos ver ha clasificado cada token de acuerdo a la nomenclatura EAGLES.

Lemmatization

```
: nlp = stanza.Pipeline(lang='en', processors='tokenize,mwt,pos,lemma') #processors needed for lemmatization
  doc = nlp('Javier has been very excited for applying lemmatization')
print(*[f'word: {word.text+" "}\tlemma: {word.lemma}' for sent in doc.sentences for word in sent.words], sep='\n')
  2020-04-28 13:21:57 WARNING: Can not find mwt: default from official model list. Ignoring it.
  2020-04-28 13:21:57 INFO: Loading these models for language: en (English):
  | Processor | Package |
    tokenize I ewt
    lemma
               j ewt
  2020-04-28 13:21:57 INFO: Use device: cpu
  2020-04-28 13:21:57 INFO: Loading: tokenize
  2020-04-28 13:21:57 INFO: Loading: pos
  2020-04-28 13:21:58 INFO: Loading: lemma
  2020-04-28 13:21:58 INFO: Done loading processors!
  word: Javier
                   lemma: Javier
  word: has
                   lemma: have
  word: been
                   lemma: be
  word: very
                   lemma: verv
  word: excited
                   lemma: excited
  word: for
                   lemma: for
  word: applying lemma: apply
  word: lemmatization
                            lemma: lemmatization
```

Dependency parsing

```
nlp = stanza.Pipeline(lang='en', processors='tokenize,mwt,pos,lemma,depparse')
doc = nlp('This processor creates a syntactic tree')
head id: 2
id: 1 word: This
                                head: processor deprel: det
id: 2 word: processor head id: 3
                              head: creates deprel: nsubj
                             head: root
id: 3 word: creates head id: 0
                                           deprel: root
     word: a head id: 6 head: tree deprel: det
id: 4
id: 5
      word: syntactic head id: 6 head: tree
                                            deprel: amod
id: 6 word: tree
                head id: 3
                               head: creates deprel: obj
```

FREELING

FreeLing es una biblioteca de C ++ que proporciona funcionalidades de análisis de lenguaje (morphological analysis, named entity detection, PoS-tagging, parsing, Word Sense Disambiguation, Semantic Role Labelling, etc.) para una variedad de idiomas.

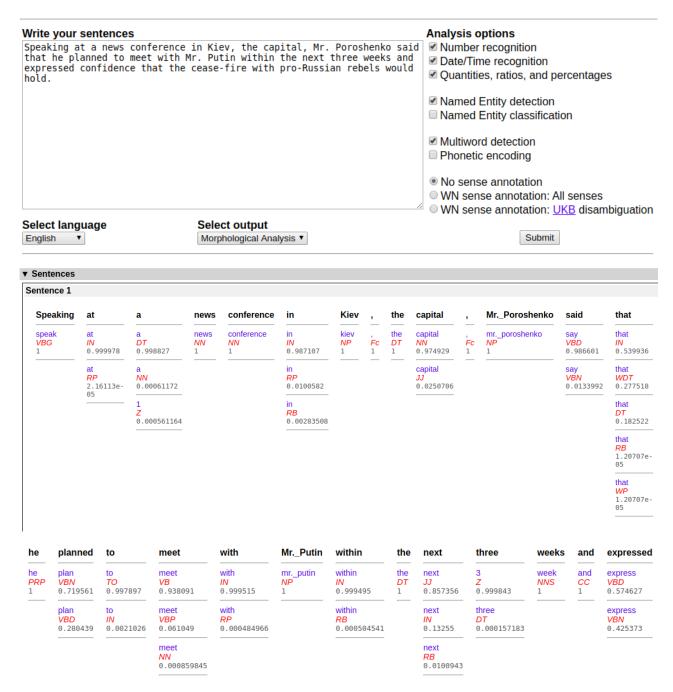
Su sitio web contiene una demo que permite interactuar con ella para realizar dichas tareas.

Como bien sabemos para la ejecución de ciertas tareas es necesario ejecutar tareas previas, el demo de Freeling no contiene la tarea de tokenization ni lemmatization por lo cual introduciremos todas juntas en el análisis morfológico.

Tokenization, morphological analysis y lemmatization

FreeLing 4.1 - An Open-Source Suite of Language Analyzers

Nothing more than FreeLing



Como podemos observar en la imagen anterior la demo tiene como salida el conjunto de tokens de color negro con su lemma de color azul (said -> say) y su información morfológica en formato EAGLE

Full parsing y árbol sintáctico

Al ejecutar esta tarea en la demo arroja como resultado todos los procesamientos anteriores además de indicar el árbol sintáctico asociado a dicho texto.

Sentence 1



